

Лицей Академии Яндекса

Линейные модели

Ермакова Анна, аналитик

План лекции

- 1 | Введение в линейные модели
- 2 | Линейная регрессия
- 3 | Аналитическое решение линейной регрессии
- 4 | Регуляризация
- 5 | Параметры и гиперпараметры

1



Введение в линейные модели

Введение в линейные модели

› Что такое линейная модель?

$x = (x_1, x_2, \dots, x_n)$ – вектор признаков

y – ответ

Классификация: $y \in \{0, 1, \dots, K\}$, где $0, 1, \dots, K$ – номера классов

Регрессия: $y \in \mathbb{R}$

Введение в линейные модели

› Что такое линейная модель?


$f(x)$ - модель

$f(x) = w_0 + w_1x_1 + w_2x_2 + \dots + w_nx_n$ - линейная модель, w_i - веса модели

$f(x) = w_0 + \langle w, x \rangle$ - линейная модель в краткой записи

Введение в линейные модели


- › Линейная модель регрессии в случае $n = 1$



x – единственный признак
 y – ответ

Введение в линейные модели

› Линейная модель регрессии в случае $n = 1$



$$y = a_3x + b_3$$

x – единственный признак


y – ответ

a_i, b_i – параметры модели i

$a_ix + b_i$ – модель i

Введение в линейные модели

› Линейная модель регрессии в случае $n = 1$



x – единственный признак


y – ответ

a_i, b_i – параметры модели i

$a_ix + b_i$ – модель i

Введение в линейные модели

› Линейная модель регрессии в случае $n = 1$



x – единственный признак


y – ответ

a_i, b_i – параметры модели i

$a_ix + b_i$ – модель i

Введение в линейные модели

› Линейная модель классификации в случае $n = 2$



x_1, x_2 — признаки


y — ответ

a, b, c — параметры модели

$ax_1 + bx_2 + c$ — модель

Введение в линейные модели

› Линейная модель классификации в случае $n = 2$



x_1, x_2 — признаки

y — ответ

a, b, c — параметры модели

$ax_1 + bx_2 + c$ — модель

Введение в линейные модели

› Свойства линейных моделей

С одной стороны:

- Легко интерпретируемы

С другой:

- Подходят только для простых задач
- Плохо справляются с зависимыми признаками
- Сильно зависят от конкретной обучающей выборки

2



Линейная регрессия

Линейная регрессия

› Матричная запись линейной регрессии

$\{X, y\}$ – датасет

$X = \{x_i\}_{i=1}^m$, $x_i \in \mathbb{R}^n$ - матрица признаков

$y = \{y_i\}_{i=1}^m$, $y_i \in \mathbb{R}$ - вектор ответов

$$X = \begin{pmatrix} x_{1_1} & x_{1_2} & \dots & x_{1_n} \\ x_{2_1} & x_{2_2} & \dots & x_{2_n} \\ \vdots & \vdots & \ddots & \vdots \\ x_{m_1} & x_{m_2} & \dots & x_{m_n} \end{pmatrix}$$

$$y = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_m \end{pmatrix}$$

Линейная регрессия

› Матричная запись линейной регрессии

$$X = \{x_i\}_{i=1}^m, x_i \in \mathbb{R}^n$$

$$y = \{y_i\}_{i=1}^m, y_i \in \mathbb{R}$$

$$w = (w_0, w_1, w_2, \dots, w_n), w_i \in \mathbb{R} - \text{вектор весов}$$

$$f(x_i) = w_0 + \langle w, x_i \rangle$$

Линейная регрессия

› Матричная запись линейной регрессии

$$f(x_i) = w_0 + \langle w, x_i \rangle$$

$f(x_i) = \langle w, x_i \rangle$ - общепринятая запись

$$w_0 + (x_{i_1} \quad \dots \quad x_{i_n}) \begin{pmatrix} w_1 \\ \vdots \\ w_n \end{pmatrix} = \begin{pmatrix} 1 & x_{i_1} & \dots & x_{i_n} \end{pmatrix} \begin{pmatrix} w_0 \\ w_1 \\ \vdots \\ w_n \end{pmatrix}$$

Линейная регрессия

› Матричная запись линейной регрессии

$$X = \{x_i\}_{i=1}^m, x_i \in \mathbb{R}^n$$

$$y = \{y_i\}_{i=1}^m, y_i \in \mathbb{R}$$


$$f(x_i) = \langle w, x_i \rangle$$

$$f(X) = Xw \approx y$$

$$f(X) = \begin{pmatrix} 1 & x_{1_1} & x_{1_2} & \cdots & x_{1_n} \\ 1 & x_{2_1} & x_{2_2} & \cdots & x_{2_n} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{m_1} & x_{m_2} & \cdots & x_{m_n} \end{pmatrix} \begin{pmatrix} w_0 \\ w_1 \\ w_2 \\ \vdots \\ w_n \end{pmatrix} \approx \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_m \end{pmatrix}$$

Линейная регрессия

› Функции потерь и функция риска




$L(y_i, f(x_i))$ - функция потерь на паре (x_i, y_i)

$L(f, X, y)$ - функция потерь на всем датасете

$$L(f, X, y) \rightarrow \min_w$$

Линейная регрессия

› Функции потерь и функция риска



Евклидово расстояние:

$$L(f, X, y) = \sum_{i=1}^m (y_i - f(x_i))^2$$

MSE:


$$L(f, X, y) = \frac{1}{m} \sum_{i=1}^m (y_i - f(x_i))^2$$

MAE:

$$L(y_i, f(x_i)) = \frac{1}{m} \sum_{i=1}^m |y_i - f(x_i)|$$

Линейная регрессия

› Функции потерь и функция риска



$$L(f, X, y) = \sum_{i=1}^m L(y_i, f(x_i)) = \sum_{i=1}^m (y_i - f(x_i))^2$$

	(1, 2)	(3, 5)	(3, 10)	(6, 6)	$Q(X)$
$x + 2$	1	0	25	4	30
$\frac{3}{2}x - 9$					
$-3x + 30$	625	256	121	36	1038

Линейная регрессия

› Функция риска в матричной форме

$$L(f, X, y) = \sum_{i=1}^m (y_i - f(x_i))^2$$

Линейная регрессия

› Функция риска в матричной форме

$$L(f, X, y) = \sum_{i=1}^m (y_i - f(x_i))^2 = \sum_{i=1}^m (y_i - \langle x_i, w \rangle)^2$$

Линейная регрессия

› Функция риска в матричной форме

$$L(f, X, y) = \sum_{i=1}^m (y_i - f(x_i))^2 =$$
$$\sum_{i=1}^m (y_i - \langle x_i, w \rangle)^2 = \sum_{i=1}^m (y_i - \langle x_i, w \rangle)(y_i - \langle x_i, w \rangle)$$

Линейная регрессия

› Функция риска в матричной форме

$$L(f, X, y) = \sum_{i=1}^m (y_i - f(x_i))^2 =$$
$$\sum_{i=1}^m (y_i - \langle x_i, w \rangle)^2 = \sum_{i=1}^m (y_i - \langle x_i, w \rangle)(y_i - \langle x_i, w \rangle) = \langle y - Xw, y - Xw \rangle$$

Пояснение:

$$Xw = \begin{pmatrix} 1 & x_{1_1} & x_{1_2} & \dots & x_{1_n} \\ 1 & x_{2_1} & x_{2_2} & \dots & x_{2_n} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{m_1} & x_{m_2} & \dots & x_{m_n} \end{pmatrix} \begin{pmatrix} w_0 \\ w_1 \\ \vdots \\ w_n \end{pmatrix} = \begin{pmatrix} -x_1 & - \\ -x_2 & - \\ \vdots & \\ -x_m & - \end{pmatrix} \begin{pmatrix} w_0 \\ w_1 \\ \vdots \\ w_n \end{pmatrix} = \begin{pmatrix} \langle x_1, w \rangle \\ \langle x_2, w \rangle \\ \vdots \\ \langle x_m, w \rangle \end{pmatrix}$$

Линейная регрессия

› Функция риска в матричной форме

$$L(f, X, y) = \sum_{i=1}^m (y_i - f(x_i))^2 =$$

$$\sum_{i=1}^m (y_i - \langle x_i, w \rangle)^2 = \sum_{i=1}^m (y_i - \langle x_i, w \rangle)(y_i - \langle x_i, w \rangle) = \langle y - Xw, y - Xw \rangle = |y - Xw|^2$$

Линейная регрессия

› Функция риска в матричной форме

$$L(f, X, y) = \|y - Xw\|^2 = \langle y - Xw, y - Xw \rangle = \langle y, y \rangle - \langle y, Xw \rangle - \langle Xw, y \rangle + \langle Xw, Xw \rangle$$

Пояснение:

$$a, b, c, d \in \mathbb{R}^n$$

$$\begin{aligned} \langle a + b, c - d \rangle &= \\ (a_1 + b_1)(c_1 - d_1) + (a_2 + b_2)(c_2 - d_2) + \dots + (a_n + b_n)(c_n - d_n) &= \\ a_1c_1 - a_1d_1 + b_1c_1 - b_1d_1 + a_2c_2 - a_2d_2 + b_2c_2 - b_2d_2 + \dots + a_nc_n - a_nd_n + b_nc_n - b_nd_n &= \\ (a_1c_1 + a_2c_2 + \dots + a_nc_n) - (a_1d_1 + a_2d_2 + \dots + a_nd_n) + (b_1c_1 + b_2c_2 + \dots + b_nc_n) - (b_1d_1 + b_2d_2 + \dots + b_nd_n) &= \\ \langle a, c \rangle - \langle a, d \rangle + \langle b, c \rangle - \langle b, d \rangle \end{aligned}$$

Линейная регрессия

› Функция риска в матричной форме

$$\begin{aligned} L(f, X, y) &= \langle y, y \rangle - \langle y, Xw \rangle - \langle Xw, y \rangle + \langle Xw, Xw \rangle = \langle y, y \rangle - 2\langle y, Xw \rangle + \langle Xw, Xw \rangle \\ &= y^T y - 2y^T Xw + (Xw)^T Xw \\ &= y^T y - 2y^T Xw + w^T X^T Xw \end{aligned}$$

Пояснение:

$$a, b \in \mathbb{R}^n = \mathbb{R}^{n \times 1}$$

$$a^T, b^T \in \mathbb{R}^{1 \times n}$$

$$\langle a, b \rangle = \langle b, a \rangle$$

$$a^T b = (a_1 \quad a_2 \quad \cdots \quad a_n) \begin{pmatrix} b_1 \\ b_2 \\ \vdots \\ b_n \end{pmatrix} = a_1 b_1 + a_2 b_2 + \cdots + a_n b_n = \langle a, b \rangle$$

3



Аналитическое решение линейной регрессии

Аналитическое решение линейной регрессии

› Вывод формулы оптимального вектора весов w^*

$$L(f, X, y) = y^T y - 2y^T Xw + w^T X^T Xw \rightarrow \min_w$$

Пусть w^* - значение вектора весов w , в котором $L(f, X, y)$ - минимально

Значит, w^* - локальный экстремум $L(f, X, y)$ и значит производная $L(f, X, y)$ в точке w^* равна 0.

$$L'_w(f, X, y) = 0$$

Аналитическое решение линейной регрессии

› Вывод формулы оптимального вектора весов w^*

$$L'_w(f, X, y) = 0$$

$$L'_w(f, X, y) = (y^T y - 2y^T Xw + w^T X^T Xw)'_w =$$

$$(y^T y)'_w - (2y^T Xw)'_w + (w^T X^T Xw)'_w =$$

$$0 - 2X^T y + 2X^T Xw = 0$$

Аналитическое решение линейной регрессии

› Вывод формулы оптимального вектора весов w^*

$$0 - 2X^T y + 2X^T X w = 0$$

$$2X^T y = 2X^T X w$$

$$X^T y = X^T X w$$

$$(X^T X)^{-1} X^T y = (X^T X)^{-1} (X^T X) w$$

$$(X^T X)^{-1} X^T y = w = w^*$$

Аналитическое решение линейной регрессии

› Проблемы

1. Необратимость матрицы $X^T X$

- Признаки скоррелированы между собой
- Объектов в выборке меньше, чем признаков

2. Вычислительная сложность обращения больших матриц

4



Регуляризация

Регуляризация

› Регуляризация

$L(f, X, y) = |y - Xw|^2$ - стандартная функция потерь

$L(f, X, y) = |y - Xw|^2 + \lambda^2 |w|^2$ - функция потерь с l2-регуляризацией
 $|w|^2 = w_1^2 + w_2^2 + \dots + w_n^2$

$L(f, X, y) = |y - Xw|^2 + \lambda |w|$ - функция потерь с l1-регуляризацией
 $|w| = |w_1| + |w_2| + \dots + |w_n|$

Регуляризация

› L2-регуляризация

$$w^* = (X^T X)^{-1} X^T y$$



$$\hat{w} = (X^T X + \lambda^2 E)^{-1} X^T y$$

$$L(f, X, y) = |y - Xw|^2$$

$$L(f, X, y) = |y - Xw|^2 + \lambda^2 |w|^2$$

5



Параметры и гиперпараметры

Параметры и гиперпараметры

› Примеры и свойства

Параметры	Гиперпараметры
Оптимизируются во время обучения	Фиксированы до обучения
Выбор зависит от тренировочной выборки	Выбор зависит от валидационной выборки

Что является параметрами и гиперпараметрами линейной регрессии?


- Параметры – вектор весов w
- Гиперпараметры - регуляризация

Параметры и гиперпараметры

- › Как правильно оценивать модели / сравнивать модели с наилучшими гиперпараметрами?
- Разделение на три выборки – трейн, тест, валидация
- Кросс-валидация


Параметры и гиперпараметры

› Разделение на три выборки – трейн, тест, валидация



Параметры и гиперпараметры

› Кросс-валидация



Параметры и гиперпараметры

- › Как перебирать гиперпараметры?
- **Grid-search** – перебор по сетке (фиксируем несколько значений для каждого гиперпараметра, обучаем и тестируем модель на каждой комбинации, выбираем лучшую)
- **Random-search** – выбор из распределения (для каждого гиперпараметра задаем распределение, комбинацию гиперпараметров выбираем семплированием из этого распределения)