



Метод градиентного спуска

Ермакова Анна, аналитик

План лекции

- 1 | Линейная регрессия
- 2 | Метод градиентного спуска
- 3 | Метод градиентного спуска для случая линейной регрессии
- 4 | Метод стохастического градиентного спуска
- 5 | Метод градиентного спуска с импульсом

1



Линейная регрессия

Линейная регрессия

› В предыдущей серии – постановка задачи линейной регрессии

$\{X, y\}$ – датасет

$X = \{x_i\}_{i=1}^m$, $x_i \in \mathbb{R}^n$ - матрица признаков


$y = \{y_i\}_{i=1}^m$, $y_i \in \mathbb{R}$ - вектор ответов

$w = (w_0, w_1, w_2, \dots, w_n)$, $w_i \in \mathbb{R}$ - вектор весов

Модель:

$f(x_i) = w_0 + \langle w, x_i \rangle$ - на одном объекте выборки

$f(X) = Xw$ – на всей выборке



Линейная регрессия


› В предыдущей серии – постановка задачи линейной регрессии

MSE minimization:

$$L(f, X, y) = \frac{1}{m} \sum_{i=1}^m (y_i - f(x_i))^2 \rightarrow \min_w$$

Аналитическое решение:

$$w = (X^T X)^{-1} X^T Y$$



Линейная регрессия

› Ограничения аналитического решения линейной регрессии

Вычислительная сложность:

- Нужно обращаться и перемножать большие матрицы
- Данные могут не поместиться в память

Сильные ограничения на модель и лосс (иначе аналитического решения может просто не быть)

2




Метод градиентного спуска

Метод градиентного спуска

› Локальный экстремум функции

Локальный экстремум функции – это максимальное или минимальное значение функции на заданном подмножестве области определения.

Производная ноль ($f'(x) = 0$) $\Leftrightarrow x$ - **локальный экстремум**.




Метод градиентного спуска

› Определение градиентного спуска

Градиент - это направление скорейшего роста функции.

Метод градиентного спуска – это способ нахождения локального минимума функции.

Идея – идти **в направлении наискорейшего спуска** (убывания), оно задается антиградиентом.



Метод градиентного спуска

› Определение градиента в терминах линейной алгебры

Градиент — это вектор, каждая координата которого представляет собой производную функции по этой координате.

$$x \in \mathbb{R}^n, f(x): \mathbb{R}^n \rightarrow \mathbb{R}, \text{ тогда } \mathbf{градиент} \text{ вычисляется как } \nabla f(x) = \begin{pmatrix} \frac{\partial f}{\partial x_1}(x) \\ \vdots \\ \frac{\partial f}{\partial x_n}(x) \end{pmatrix}$$

Тогда **шаг градиентного спуска** вычисляется как $x^{k+1} = x^k - \gamma \nabla f(x^k)$, где $\gamma \in \mathbb{R}$ - константа.

Метод градиентного спуска

› Пример вычисления шага градиентного спуска

$z = f(x, y) = x^2 + y^2$ - функция

$(x_0, y_0) = (0.8, 0.8)$ – начальное приближение


$\gamma = 0.1$ – размер шага

Градиент:

$\nabla f(x, y) = (2x, 2y)$ - градиент

Шаг градиентного спуска:

$(x^{k+1}, y^{k+1}) = (x^k, y^k) - \gamma(2x^k, 2y^k)$



3



Метод градиентного спуска для случая линейной регрессии

Метод градиентного спуска для случая линейной регрессии

› Вычисляем шаг градиентного спуска для линейной регрессии с MSE

$$L(f, X, y) = \frac{1}{m} \sum_{i=1}^m (y_i - f(x_i))^2 = \frac{1}{m} \sum_{i=1}^m (y_i - w_0 + \langle w, x_i \rangle)^2 \rightarrow \min_w$$

$L(f, X, y)$ - функция, зависящая от w

Нужно найти такой вектор w , в котором $L(f, X, y)$ будет минимальной.
Значит, нужно продифференцировать $L(f, X, y)$ по w .

Шаг градиентного спуска:

$$w^{k+1} = w^k - \gamma \nabla L(w^k, X, y)$$

$w^k = (w^k_1, \dots, w^k_n)$ - вектор весов на k -ом шаге градиентного спуска

Пример для линейной регрессии

› Одномерный случай – один признак ($n = 1$)

На всей выборке:

$$f(X) = Xw$$

$$L(f, X, y) = \frac{1}{m} \sum_{i=1}^m (y_i - w_0 + \langle w, x_i \rangle)^2$$

$$w^{k+1} = w^k - \gamma \nabla L(w^k, X, y) = w^k - \gamma \frac{1}{m} \sum_{i=1}^m \nabla L(w^k, x_i, y_i)$$

Пример для линейной регрессии

› Одномерный случай – один признак ($n = 1$)

Градиент на одном объекте выборки:

$$f(x) = w_1 \cdot x_i + w_0$$

$$L(f, x_i, y) = (y_i - w_0 + \langle w, x_i \rangle)^2$$

$$\begin{aligned}\nabla L(w^k, x_i, y_i) &= \nabla (w_1^k \cdot x_i + w_0^k - y_i)^2 \\ &= \nabla ((w_1^k \cdot x_i)^2 + (w_0^k)^2 + y_i^2 + 2w_0^k w_1^k x_i - 2w_1^k x_i y_i - 2w_0^k y_i) \\ &= (2w_0^k + 2w_1^k x_i - 2y_i, 2w_1^k x_i + 2w_0^k x_i - 2x_i y_i)\end{aligned}$$

Пример для линейной регрессии

› Одномерный случай – один признак ($n = 1$)

На всей выборке:

$$f(X) = Xw$$

$$L(f, X, y) = \frac{1}{m} \sum_{i=1}^m (y_i - w_0 + \langle w, x_i \rangle)^2$$

$$w^{k+1} = w^k - \gamma \nabla L(w^k, X, y) = w^k - \gamma \frac{1}{m} \sum_{i=1}^m \nabla L(w^k, x_i, y_i)$$

$$= w^k - \gamma \frac{1}{m} \sum_{i=1}^m (2w_0^k + 2w_1^k x_i - 2y_i, 2w_1^k x_i + 2w_0^k x_i - 2x_i y_i)$$

4



Метод стохастического градиентного спуска

Метод стохастического градиентного спуска

› Определение

На каждом шаге считаем градиент не по всей выборке $\{X, Y\}$, а по подвыборке размера l $\{X^l, Y^l\}$

$$\{X, Y\}: \quad w^{k+1} = w^k - \gamma \frac{1}{m} \sum_{i=1}^m (2w_0^k + 2w_1^k x_i - 2y_i, 2w_1^k x_i + 2w_0^k x_i - 2x_i y_i)$$

$$\{X^l, Y^l\}: \quad w^{k+1} = w^k - \gamma \frac{1}{l} \sum_{i=1}^l (2w_0^k + 2w_1^k x_i - 2y_i, 2w_1^k x_i + 2w_0^k x_i - 2x_i y_i)$$

Метод стохастического градиентного спуска

› Особенности

Плюсы

- Позволяет заметно ускорить обучение
- Позволяет учиться на действительно больших данных
- Можно обучаться на потоке входных данных, когда все время поступают новые

Минусы

- Может не сходиться или сходиться слишком медленно
- Решение может быть неустойчивым

Метод стохастического градиентного спуска

› Выбор шага градиентного спуска

$w^{k+1} = w^k - \gamma \nabla L(w^k, X, y)$ - шаг градиентного спуска

γ может быть обновлён динамически в зависимости от того, что получилось после шага градиентного спуска.


Примеры эвристики изменения шага:

- Если значение функции после шага градиентного спуска увеличилось, то размер шага слишком большой. Вернитесь на предыдущий шаг и уменьшите γ .
- Если значение функции после шага градиентного спуска уменьшилось, попробуйте увеличить шаг.


Метод стохастического градиентного спуска

› Сравнение с обычным

Stochastic Gradient Descent



Gradient Descent



Метод стохастического градиентного спуска

› Критерии останова

- Незначительное изменение лосса
- Достижение заданного количества шагов
- Очень маленькое (незначительное) изменение параметров: $w^{n+1} - w^n < \varepsilon$, где $\varepsilon > 0$ – близко к 0

4



Метод градиентного спуска с импульсом

Метод градиентного спуска с импульсом

› Определение

Шаг градиентного спуска:

$$w^{k+1} = w^k - \gamma \nabla L(w^k, X, y) + \alpha(w^k - w^{k-1})$$

Формула выводится из такого определения:

$$\nabla w^{k+1} = \alpha \nabla w^k - \gamma \nabla L(w^k, X, y)$$

$$w^{k+1} = w^k + \nabla w^{k+1}$$