

Разбираем DALL-E и подобные модели

Генерация картинок с помощью text2image моделей

Занятие 3


План занятия

Теоретическая часть:

- dVAE
- Погружение в языковые модели
- Архитектура DALL-E, ruDALL-E


Общая схема DALL-E

- Text2image модель, выпущена в 2021 OpenAI



Общая схема DALL-E

- Основные компоненты – Text Encoder (языковая Transformer-модель GPT-3) и Image Generator (dVAE)



Общая схема DALL-E

Обучение DALL-E:

- Text Encoder и Image Generator обучаются отдельно
- Датасет для обучения – пары (картинка, текстовое описание)

Сначала Image Generator (VAE) обучается кодировать-декодировать картинки без потери качества.

Далее Text Encoder обучается переводить текст в закодированный с помощью VAE вектор.

Image часть DALL-E

dVAE – автоэнкодер с дискретным скрытым пространством, немного отличается от VQ-VAE.

VQ-VAE:

$z_e(x)$ - выходной вектор энкодера

$z_q(x) = \operatorname{argmin}_i \|z_e(x) - e_i\|$ - ближайший вектор к $z_e(x)$ из codebook, передается в декодер

Проблема: нельзя однозначно определить самый близкий к $z_e(x)$ вектор из codebook

Решение: dVAE

Image часть DALL-E

dVAE: Для выходного вектора энкодера $z_e(x)$ выбираем не ближайший вектор из codebook, а строим распределение вероятностей по всем векторам codebook. Для декодера выбираем вектор из codebook с помощью этого распределения.




Image часть DALL-E

Входные данные: изображения 256x256

dVAE:

- Размер codebook = 8192 вектора
- Энкодер выдает сетку 32x32 из векторов, каждый из которых кодируется числом (индексом соответствующего вектора из codebook)

Погружение в языковые модели

На улице идет дождь, поэтому мне нужно взять с собой _____

Языковая модель – это распределение вероятностей по последовательностям слов.

$x_1, x_2, \dots, x_k$ - последовательность слов

$$p(x_1, x_2, \dots, x_k) = p(x_1)p(x_2|x_1)p(x_3|x_1x_2) \dots p(x_k|x_1x_2 \dots x_{k-1})$$

$$p(A|B) = \frac{P(AB)}{P(B)}$$

Погружение в языковые модели

N-grams:

- Берем большой массив текста и считаем, сколько раз каждая уникальная последовательность из N слов встретилась в тексте
- Используем эти частоты для вычисления условной вероятности N -ого слова в последовательности $N - 1$ предыдущих слов.

Слова	Частоты	Вероятность второго слова по первому
вкусный салат	341	0.39
вкусный торт	543	0.61

$$p(\text{салат}|\text{вкусный}) = \frac{p(\text{вкусный салат})}{p(\text{вкусный})} = \frac{341}{884} = 0.39$$

$$p(\text{торт}|\text{вкусный}) = \frac{p(\text{вкусный торт})}{p(\text{вкусный})} = \frac{543}{884} = 0.61$$

Погружение в языковые модели

N-grams, проблемы:

- Предполагают, что слово не зависит от более, чем N предыдущих слов
- При большом N существует слишком много грамматически и лексически правильных последовательностей, которых может не быть в обучающем массиве
- Не учитывает сходства между последовательностями

Я ел сегодня блины на завтрак

У меня сегодня были блины на завтрак

Погружение в языковые модели

Закодируем последовательности слов векторами

Идея 1: закодируем каждую N-gram как one-hot вектор размерности, равной числу всех последовательностей длины N.

Идея 2: обучим нейронную сеть кодировать последовательности слов.

**sparse vectors
(1-gram representations)**

dog	cat
0	0
0	1
0	0
1	0
0	0
0	0
⋮	⋮

these sparse vectors are of dimension equal to the vocab size

**dense vectors
(neural representations)**

dog	cat
1.2	1.8
0.3	0.1
-1	-2
9.3	8.9
0.1	0.2
12	10


dense vectors can be of any dimension you want, usually much smaller than the vocab size

Погружение в языковые модели


N-gram модель - обучаем модель строить для каждого слова в словаре строить вектор длины 64 (градиентный спуск, MSE).

Предсказание следующего слова – конкатенируем векторы предыдущих слов в один и пропускаем его через выходной слой.


Такие модели отражают некоторые взаимосвязи между словами:



Male-Female



Verb tense



Country-Capital

Погружение в языковые модели

N-gram модель, проблемы:

- Предполагает, что слово не зависит от более, чем N предыдущих слов
- При большом N существует слишком много грамматически и лексически правильных последовательностей, которых может не быть в обучающем массиве (не релевантно)
- Не учитывает сходства между последовательностями (решено)
- Для каждого слова 1 вектор → нельзя выразить значения в разных контекстах


Мышь (животное)

Мышь (компьютерная)

Погружение в языковые модели

RNN – нейронные сети, учитывающие контекст

Слова в последовательности подаются в сеть одно за другим. Для кодирования каждого нового слова учитывается вектор контекста, содержащий информацию о предыдущих словах в последовательности.



Погружение в языковые модели

RNN модель, проблемы:

- Предполагает, что слово не зависит от более, чем N предыдущих слов (частично решено)
- При большом N существует слишком много грамматически и лексически правильных последовательностей, которых может не быть в обучающем массиве (не релевантно)
- Не учитывает сходства между последовательностями (решено)
- Для каждого слова 1 вектор → нельзя выразить значения в разных контекстах (решено)

Погружение в языковые модели

Transformer – хранит и обновляет векторы для каждого слова в контексте

Script for Spiderman Far From Home:

The film is directed by Jon Watts and produced by Kevin Feige and Amy Pascal. The film is written by Chris McKenna, Erik Sommers, and Erik Jendresen. The movie will be released on July 5, 2019.

Also Read: Avengers Endgame: Captain America and Iron Man's friendship

Spiderman Far From Home Cast:

Tom Holland as Spiderman:

Tom Holland is an English actor. He is best known for his role as the Marvel superhero Spiderman. He is also known for his role in The Impossible, In the Heart of the Sea, and The Lost City of Z. He will reprise his role as Spiderman in Spiderman Far From Home.

Zendaya as Michelle:

Zendaya is an American actress and singer. She is best known for her role as Rocky Blue on Shake It Up and as K.C. Cooper in the

DALL-E

Train:


1. Обучаем VAE по картинкам кодировать-декодировать их без потери качества.
Закодированная картинка – вектор токенов размера $32 \times 32 = 1024$
2. Кодлируем текстовые описания в вектор токенов длины 256 с помощью Byte Pair Encoding.
3. Обучаем GPT-3 по токенам текста выдавать токены изображения.

Apply:

1. Кодлируем текстовое описание с помощью BPE
2. Применяем к токенам текста GPT-3, получаем последовательность токенов изображения
3. Применяем декодер dVAE к токенам изображения, получаем картинку


DALL-E

- Получение токенов изображения по токенам текста с помощью GPT-3



DALL-E

- Декодирование токенов изображения с помощью dVAE



Статьи

- Оригинальная статья про DALL-E <https://arxiv.org/pdf/2102.12092.pdf>
- Блог-пост от OpenAI про DALL-E <https://openai.com/blog/dall-e/>
- В двух частях про DALL-E, во второй введение в языковые модели
<https://ml.berkeley.edu/blog/posts/vq-vae/>
- Example notebook VAE из DALL-E от OpenAI <https://github.com/openai/DALL-E>
- Очень подробно про Transformer <https://jalammar.github.io/illustrated-transformer/>