

Разбираем Stable Diffusion

Генерация картинок с помощью text2image моделей

Занятие 5

План занятия

Теоретическая часть:

- Stable Diffusion


Общая схема Stable diffusion

- Text2image модель, выпущена в 2022



Общая схема Stable diffusion

- Основные компоненты – Text Encoder (языковая модель CLIP) и Image Generator (VAE + диффузия)



Общая схема Stable diffusion

Обучение Stable Diffusion:

- Text Encoder и Image Generator обучаются отдельно
- Датасет для обучения – пары (картинка, текстовое описание)

Сначала Text Encoder обучается переводить текст в вектор. Затем Image Generator обучается переводить эти векторы в картинки.

Текстовая часть Stable Diffusion

Нейросеть CLIP

Обучается на массиве из 400 млн изображений и подписей к ним

IMAGE




Photo pour Japanese
pagoda and old house in
Kyoto at twilight - image
libre de droit

CAPTION



Soaring by Peter
Eades



far cry 4 concept art is the
reason why it 39 s a
beautiful game vg247.
Black Bedroom Furniture
Sets. Home Design Ideas

Текстовая часть Stable Diffusion

Обучение – кодируем изображение и подпись к нему, затем сравниваем векторы с помощью косинусной меры.

Обновляем веса моделей так, чтобы при следующей итерации кодирования получившиеся векторы были более схожи.

Результат – кодировщики, способные создавать векторы, в которых изображение собаки и предложение «изображение собаки» схожи.




Image часть Stable Diffusion

Используем diffusion модель.

Модифицируем **входные данные** diffusion модели – передаем **закодированный с помощью Text Encoder текст, номер шага и зашумленное изображение**.




Image часть Stable Diffusion

Архитектура diffusion модели - Unet

Unet – сверточная сеть, создана в 2015 для сегментации медицинских изображений.




Image часть Stable Diffusion

Работа в пиксельном пространстве вычислительно тяжелая (сотни GPU-дней) → перейдем в сжатое скрытое пространство.

Поместим diffusion модель внутри VAE




Image часть Stable Diffusion

- Обучим VAE на датасете картинок.
- Вместо картинок будем выполнять процесс диффузии со скрытыми представлениями этих картинок.
- Для обучения диффузии будем накладывать шум не на картинки, а на скрытое представление.
- При обратной диффузии будем получать «чистое» скрытое представление картинки.





Image часть Stable Diffusion



Stable Diffusion

Train:


1. Обучаем CLIP по парам (картинка, описание) кодировать картинку и ее описание в схожие векторы.
2. Обучаем VAE по картинкам кодировать-декодировать их без потери качества.
3. Обучаем diffusion модель по зашумленному скрытому представлению картинки из энкодера VAE, вектору текста из CLIP и номеру шага предсказывать количество шума на этом шаге.

Apply:

1. Применяем CLIP к текстовому описанию и получаем вектор
2. Генерируем случайный Гауссовский шум, применяем к нему энкодер VAE, получаем скрытое представление шума
3. Добавляем к скрытому представлению шума вектор текста и применяем к ним diffusion модель 50 раз с соответствующими номерами шага. Получаем скрытое представление «чистой» картинки
4. Применяем декодер VAE к скрытому представлению «чистой» картинки и, вуаля

Stable Diffusion

- Схема Stable Diffusion из оригинальной статьи



Статьи

- Оригинальная статья про Stable Diffusion <https://arxiv.org/pdf/2112.10752.pdf>
- Как работает Stable Diffusion <https://habr.com/ru/post/693298/>
- Public-release Stable Diffusion <https://stability.ai/blog/stable-diffusion-public-release>
- Youtube-канал с короткими видео про разные модели
<https://www.youtube.com/@AICoffeeBreak/videos>